AFYON KOCATEPE ÜNİVERSİTESİ

Bilgisayar Mühendisliği Anabilim Dalı – Tezli Yüksek Lisans

YAPAY SİNİR AĞLARI DERSİ VİZE RAPORU

Dry Bean Veri Setinde İleri Beslemeli Yapay Sinir Ağlarının Deneysel Karşılaştırılması ve L2 Düzenlileştirme Analizi

Aslı Şemşimoğlu | Öğrenci No: 250763501

GitHub: https://github.com/aslisemsimoglu/DryBean-ANN-MATLAB-27Experiments

ÖZET

Bu çalışmada UCI Dry Bean veri setindeki 13.611 örnek, 16 sayısal morfolojik özellik kullanılarak yedi fasulye çeşidine sınıflandırılmıştır. MATLAB R2026b ortamında bir, iki ve üç gizli katmanlı üç ileri beslemeli yapay sinir ağı (YSA) tasarlanmıştır. Üç nominal eğitim havuzu/test oranı (%60/%40, %70/%30 ve %80/%20) ve her koşul için üç rastgele başlangıç kullanılarak 27 eğitim gerçekleştirilmiştir. Eğitim havuzunun %10'u doğrulama amacıyla ayrılmıştır. Tüm modeller 50 epoch tamamlamıştır. En yüksek ortalama test doğruluğu %60/%40 koşulundaki YSA-3 modelinde %92,946 (standart sapma 0,207 yüzde puan), en yüksek tekil test doğruluğu ise %93,0749 olarak gözlenmiştir. Tüm 27 modelde son doğrulama kaybı ilk doğrulama kaybından düşüktür. 21 modelde son doğrulama kaybı süreçteki minimum değerin üzerindedir. Bulgular mimari karmaşıklığı, eğitim veri oranı ve başlangıç rastgeleliğinin sonuçlarla ilişkisini ortaya koyarken tek veri seti ve tek bölme örneklemi nedeniyle genelleme iddiaları sınırlı tutulmuştur. Ek olarak en yüksek ortalama test doğruluğunu veren YSA-3 (%60/%40) mimarisinde üç eşleştirilmiş tohum kullanılarak *L2 = 0, 0,0001, 0,001 ve 0,01* katsayıları karşılaştırılmıştır. Üç orijinal kontrol koşusu yeniden eğitilmek yerine dokuz ek eğitim gerçekleştirilmiştir. *L2 = 0,001* koşulu %92,995 ortalama test doğruluğu üretmiş ancak orijinal *L2 = 0,0001* koşuluna göre fark yalnızca 0,049 yüzde puan olmuştur. *L2 = 0,01* koşulunda test doğruluğu %92,567'ye gerilemiştir.

Anahtar kelimeler: Yapay sinir ağları, çok sınıflı sınıflandırma, derin öğrenme, L2 düzenlileştirme, hiperparametre duyarlılık analizi, genelleme performansı, aşırı öğrenme.

1. GİRİŞ

Tarımsal ürünlerin biçimsel özelliklerine göre otomatik sınıflandırılması, görsel denetimden elde edilen sayısal özelliklerin makine öğrenmesiyle işlenmesine dayanan önemli bir uygulama alanıdır. Dry Bean veri seti, yedi fasulye türüne ait alan, çevre, eksen uzunlukları ve biçim faktörleri gibi özelliklerle bu problemin standart bir örneğini sunar [1], [2]. Çok katmanlı ileri beslemeli ağlar, doğrusal olmayan özellik etkileşimlerini öğrenebilmesi nedeniyle tablosal sınıflandırmada incelenmeye değer yöntemlerdir [3]–[7].

Çalışmanın amacı, tek bir veri seti üzerinde üç farklı YSA derinliğinin performansını karşılaştırmak, eğitim havuzu/test oranının etkisini gözlemlemek ve her koşulu üç kez tekrarlayarak sonuçların kararlılığını değerlendirmenin yanı sıra eğitim sırasında izlenen kayıp/doğruluk göstergelerini raporlamaktır. Bu çalışma yeni bir algoritma önermez ancak denetlenebilir ve tekrarlanabilir bir deney yürütür.

2. LİTERATÜR ÖZETİ

Koklu ve Ozkan [1], Dry Bean veri setini oluşturarak çok katmanlı algılayıcı, destek vektör makinesi, k-en yakın komşu ve karar ağacı modellerini karşılaştırmıştır. Geri yayılımın temel prensipleri Rumelhart vd. [3] tarafından ortaya konmuş, derin öğrenmenin temsil öğrenme yaklaşımı LeCun vd. [4] ve Goodfellow vd. [5] tarafından sistematik biçimde açıklanmıştır. Bishop [6] ile Hastie vd. [7], model karmaşıklığı, sınıflandırma ve genelleme çerçevesini sağlamaktadır. Glorot ve Bengio [8] ile He vd. [9], aktivasyon ve parametre başlangıçlarının eğitim davranışı açısından önemini incelemiştir.

Adam optimizasyon algoritması [10], yapay sinir ağlarının gradyan tabanlı eğitiminde kullanılan adaptif bir optimizasyon yöntemidir. Model karmaşıklığının kontrol edilmesi ve genelleme performansının değerlendirilmesi açısından düzenlileştirme yöntemleri önem taşımaktadır. Bu çalışmada L2 düzenlileştirme katsayısının etkisi, sabit ağ mimarisi ve eşleştirilmiş rastgele başlangıçlar altında incelenmiştir.

3. VERİ SETİ VE ÖN İŞLEME

3.1. Veri setinin yapısı

UCI Dry Bean veri seti 13.611 gözlem, 16 sayısal açıklayıcı değişken ve 7 hedef sınıftan oluşmaktadır. Sınıflar *BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SEKER ve SIRA*'dır. Özellikler doğrudan ham görüntü pikselleri değil, görüntü işleme ile elde edilmiş morfolojik ölçümlerdir [1], [2].

Özellik grubu	Değişkenler
Boyut ve çevre	Area, Perimeter, MajorAxisLength, MinorAxisLength, ConvexArea, EquivDiameter
Oran ve geometrik biçim	AspectRation, Eccentricity, Extent, Solidity, Roundness, Compactness
Biçim faktörleri	ShapeFactor1, ShapeFactor2, ShapeFactor3, ShapeFactor4

Tablo 1. Dry Bean veri setinin 16 girdi özelliği.

3.2. Bölme ve standardizasyon

Veriler üç ayrı nominal eğitim havuzu/test oranıyla bölünmüştür. Her eğitim havuzunun %10'u doğrulama için ayrılmış ve gerçek eğitim örnekleri üzerinde hesaplanan ortalama ve standart sapma ile z-skor standardizasyonu uygulanmıştır. Aynı bölmedeki üç mimari ve üç tekrar aynı eğitim/doğrulama/test örneklerini kullanmıştır. Bu uygulama veri sızıntısı riskini azaltır, farklı oranlar arasında ise test örneklerinin sayısı ve içeriği değişir.

Nominal oran	Eğitim (n)	Doğrulama (n)	Test (n)	Gerçek yüzdeler (E/D/T)
60/40	7.351	816	5.444	%54,0 / %6,0 / %40,0
70/30	8.576	952	4.083	%63,0 / %7,0 / %30,0
80/20	9.801	1.088	2.722	%72,0 / %8,0 / %20,0

Tablo 2. Nominal oranlar ve gerçek eğitim/doğrulama/test örnek sayıları.

3.3 Veri Ön İşleme Stratejisinin Değerlendirilmesi

Bu çalışmada veri ön işleme aşaması, yapay sinir ağlarının farklı ölçeklerdeki morfolojik özelliklerden dengeli biçimde yararlanabilmesini sağlamak amacıyla tasarlanmıştır. Veri kümesindeki 16 sayısal özellik, alan ve çevre gibi farklı büyüklüklerde ölçülen değişkenlerden oluşmaktadır. Bu nedenle z-skor standardizasyonu uygulanarak özelliklerin karşılaştırılabilir ölçeklere taşınması amaçlanmıştır.

Standardizasyon parametreleri yalnızca eğitim alt kümesinden hesaplanmış, aynı parametreler doğrulama ve test kümelerine uygulanmıştır. Böylece doğrulama ve test verilerinden eğitim aşamasına istatistiksel bilgi aktarılması önlenmiştir.

Eğitim, doğrulama ve test kümelerinin birbirinden ayrılması, modelin yalnızca eğitim verisini öğrenme başarısının değil, görülmemiş örnekler üzerindeki genelleme performansının da değerlendirilmesini

sağlamıştır. Aynı veri oranındaki farklı mimarilerin ortak veri bölmelerini kullanması, mimariler arası karşılaştırmanın tutarlılığını artırmıştır.

4. METODOLOJİ: YSA MİMARİLERİ VE EĞİTİM

4.1. Mimari tasarım

Üç modelin girdi boyutu 16, çıktı boyutu 7'dir. Gizli katmanlar tam bağlantılı ve ReLU aktivasyonludur. Çıkış katmanında softmax kullanılmıştır. Gizli katman sayısı ve nöron sayısı dışında eğitim koşulları eşleştirilmiştir.

Mimari	Katman akışı	Gizli katman sayısı
YSA-1	16 → 10 (ReLU) → 7 (softmax)	1
YSA-2	16 → 20 (ReLU) → 10 (ReLU) → 7 (softmax)	2
YSA-3	16 → 32 (ReLU) → 16 (ReLU) → 8 (ReLU) → 7 (softmax)	3

Tablo 3. Deneylerde kullanılan üç YSA mimarisi.

Literatürde, yapay sinir ağlarının genelleme performansını iyileştirmek amacıyla Dropout [11], eğitim sürecinin kararlılığını ve yakınsama davranışını desteklemek amacıyla ise Batch Normalization [12] yöntemleri önerilmiştir. Bu çalışmada söz konusu yöntemler uygulanmamış; mimari derinliğinin ve L2 düzenlileştirme katsayısının etkilerini değerlendirebilmek amacıyla deneysel yapılandırma bu değişkenler üzerinden sınırlandırılmıştır.

4.2. Eğitim yapılandırması

Parametre	Değer
Optimizasyon	Adam
Kayıp fonksiyonu	Çok sınıflı cross-entropy
Epoch	50
Mini-batch	128
Başlangıç öğrenme oranı	0,001
Doğrulama sıklığı	20 iterasyon
Karıştırma	Her epoch
Rastgele tohumlar	101, 202, 303

Tablo 4. Ana deneylerde kullanılan sabit eğitim hiperparametreleri.

Üç tekrar, farklı rastgele tohumlarla ağırlıkların yeniden başlatılmasını sağlar. Veri bölmesi tekrarlar arasında değişmemiştir. Dolayısıyla raporlanan standart sapma, bölme rastgeleliğini değil ağırlık başlangıcı ve eğitim sırası kaynaklı değişkenliği temsil eder. Tüm koşul modelleri ayrı MAT dosyalarına kaydedilmiştir.

4.3. Başarım ölçütleri ve eğitim izleme

Eğitim, doğrulama ve test doğruluğu doğru tahmin sayısının toplam örnek sayısına oranı olarak hesaplanmıştır. Her sınıf için kesinlik ve duyarlılığın harmonik ortalaması F1 değerini oluşturur. Macro-F1 ise yedi sınıfın F1 değerlerinin aritmetik ortalamasıdır [14]. Test cross-entropy, modelin doğru sınıfa verdiği olasılıklara dayalı olarak hesaplanmıştır. Eğitim süresince mini-batch eğitim kaybı ve doğruluğu, belirli iterasyonlarda ise tam doğrulama kümesindeki kayıp ve doğruluk izlenmiştir. Eğitim sırasında doğrulama kaybının minimuma ulaşıp daha sonra artması, olası aşırı öğrenme için tarama göstergesi olarak kullanılmıştır.

5. SONUÇLAR VE BULGULAR

5.1. 27 Deney Koşusunun Tam Sonuç Tablosu

Tablo 5, üç mimari, üç oran ve üç tekrarın tamamını ayrı satırlarda gösterir.

Mimari	Oran	Tekrar	Eğitim %	Doğrulama %	Test %	Macro-F1
YSA-1	60/40	1	92.44	90.69	92.52	0.9370
YSA-1	60/40	2	92.46	90.69	92.49	0.9374
YSA-1	60/40	3	92.57	90.81	92.43	0.9366
YSA-2	60/40	1	93.09	91.67	92.73	0.9395
YSA-2	60/40	2	93.03	91.54	92.82	0.9395
YSA-2	60/40	3	92.84	91.18	92.63	0.9391
YSA-3	60/40	1	93.09	92.16	93.06	0.9415
YSA-3	60/40	2	93.31	92.03	92.71	0.9389
YSA-3	60/40	3	93.08	91.91	93.07	0.9420
YSA-1	70/30	1	92.91	92.12	91.82	0.9306
YSA-1	70/30	2	92.92	91.81	91.99	0.9321
YSA-1	70/30	3	92.85	92.44	92.26	0.9349
YSA-2	70/30	1	93.39	92.96	92.73	0.9384
YSA-2	70/30	2	93.26	92.33	92.77	0.9388
YSA-2	70/30	3	93.23	92.54	92.21	0.9336
YSA-3	70/30	1	93.44	92.86	92.38	0.9355
YSA-3	70/30	2	93.84	93.17	92.43	0.9350
YSA-3	70/30	3	93.61	92.54	92.58	0.9373
YSA-1	80/20	1	92.56	94.21	91.48	0.9270
YSA-1	80/20	2	92.66	93.66	91.40	0.9266
YSA-1	80/20	3	92.74	94.49	91.51	0.9277
YSA-2	80/20	1	93.31	94.03	92.14	0.9325
YSA-2	80/20	2	93.23	93.93	92.25	0.9341
YSA-2	80/20	3	93.12	93.84	91.62	0.9277
YSA-3	80/20	1	93.30	94.39	92.17	0.9331
YSA-3	80/20	2	93.51	94.21	92.03	0.9316
YSA-3	80/20	3	93.35	94.30	92.21	0.9334

Tablo 5. Yirmi yedi koşunun bireysel eğitim, doğrulama ve test sonuçları.

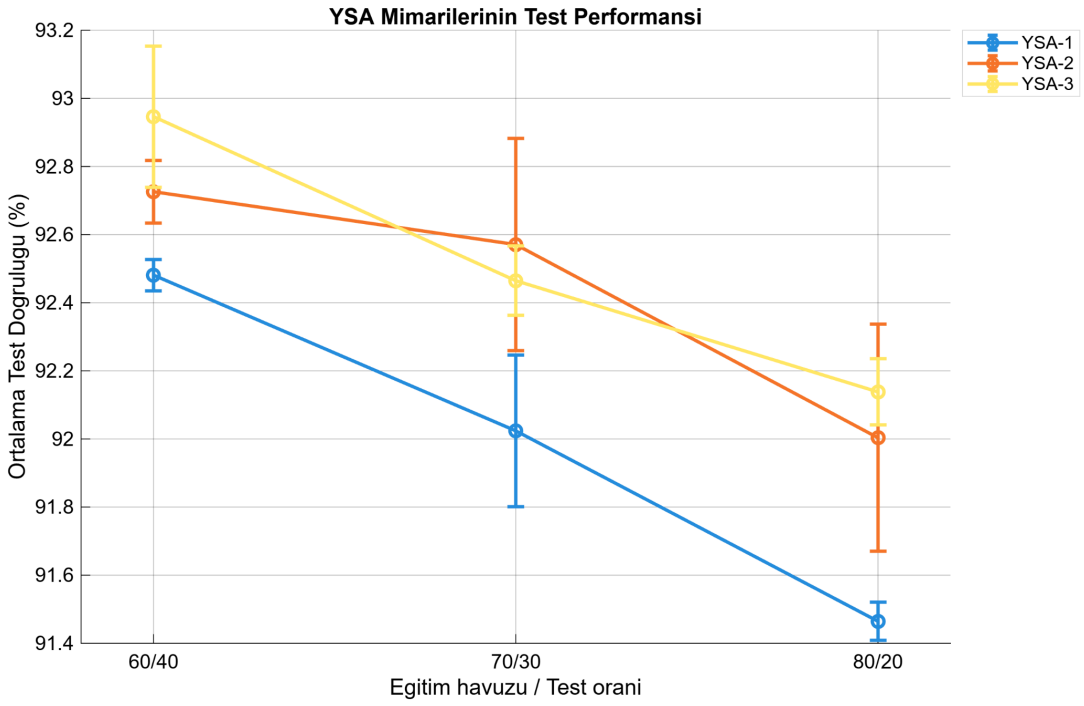
5.2. Üç tekrarın grup istatistikleri

Mimari	Oran	Test ort. %	Std. sapma (yp)	En iyi test %	Macro-F1 ort.
YSA-1	60/40	92.481	0.046	92.524	0.93698
YSA-2	60/40	92.726	0.092	92.818	0.93934
YSA-3	60/40	92.946	0.207	93.075	0.94080
YSA-1	70/30	92.024	0.222	92.261	0.93253
YSA-2	70/30	92.571	0.312	92.775	0.93692
YSA-3	70/30	92.465	0.102	92.579	0.93595
YSA-1	80/20	91.465	0.056	91.514	0.92708
YSA-2	80/20	92.003	0.333	92.248	0.93141
YSA-3	80/20	92.138	0.097	92.212	0.93270

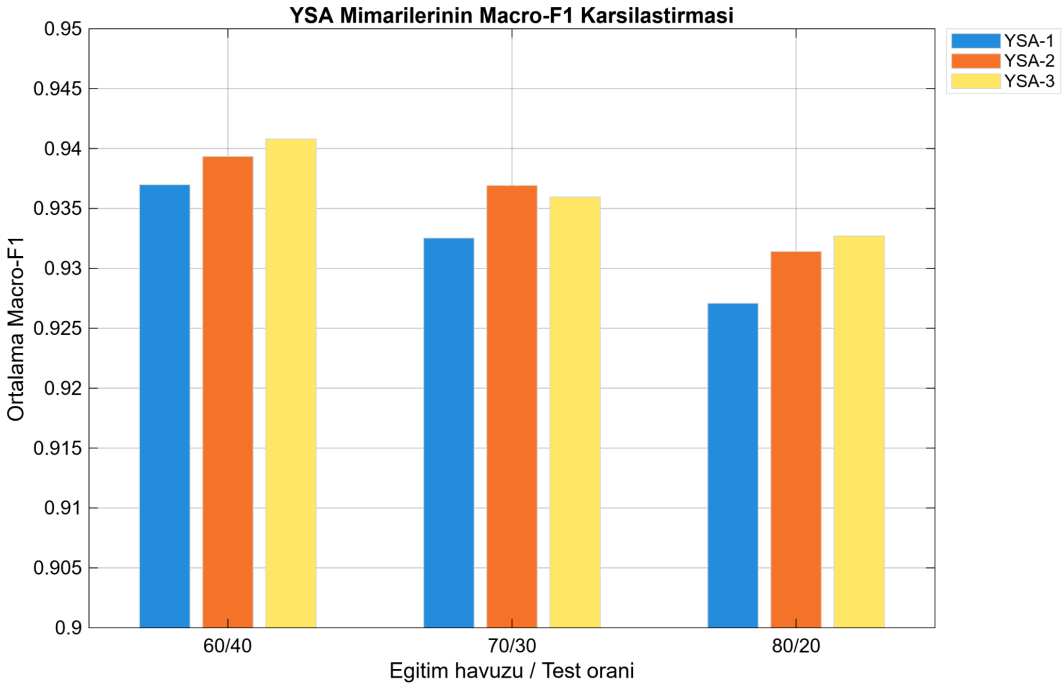
Tablo 6. Dokuz deney grubunun üç tekrar üzerinden hesaplanan özet istatistikleri (yp: yüzde puan).

En yüksek grup ortalaması YSA-3, %60/%40 koşulunda %92,946; en yüksek tekil test doğruluğu aynı koşulun üçüncü tekrarında %93,0749 olmuştur. %70/%30 oranında YSA-2 ortalama %92,571 ile en yüksek sonucu elde etmiştir. %80/%20 oranında YSA-3 ortalama %92,138 ile ilk sıradadır. Bununla birlikte gruplar arası farkların küçük olduğu ve farklı oranlarda test kümesinin değiştiği dikkate alınmalıdır.

5.3. Karşılaştırma görselleri

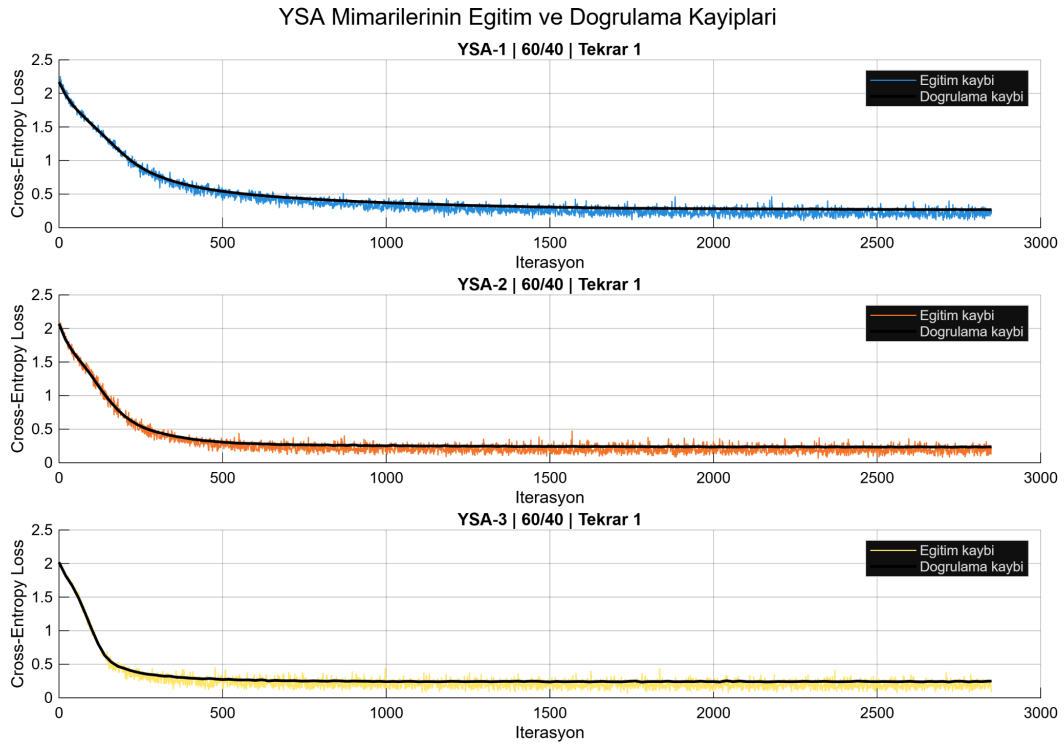


Şekil 1. Test doğruluğu ortalamaları ve üç tekrarın örnek standart sapması; her nokta aynı veri oranındaki üç eğitimin ortalamasıdır.



Şekil 2. Dokuz grubun ortalama Macro-F1 değerleri.

5.4. Eğitim eğrileri ve yakınsama



Şekil 3. %60/%40 koşulunda üç mimarinin birinci tekrarındaki mini-batch eğitim ve periyodik doğrulama kayıpları.

Bütün modellerde son doğrulama kaybı ilk doğrulama kaybından düşüktür. 21/27 modelde son doğrulama kaybı eğitim boyunca gözlenen minimumdan yüksek çıkmıştır. Bu durum olası geç dönem dalgalanma veya aşırı öğrenme açısından değerlendirilmelidir.

5.4.1. Aşırı Öğrenme ve Yetersiz Öğrenme Davranışının İncelenmesi

Yapay sinir ağlarının genelleme kapasitesini değerlendirmek amacıyla eğitim ve doğrulama kayıplarının seyri ile eğitim, doğrulama ve test doğrulukları birlikte incelenmiştir.

Gerçekleştirilen 27 eğitim koşusunun tamamında son doğrulama kaybının ilk doğrulama kaybından düşük olması, modellerin eğitim sürecinde başlangıç durumlarına kıyasla ilerleme kaydettiğini göstermektedir. Bununla birlikte, 21 koşuda son doğrulama kaybının eğitim boyunca gözlenen minimum değerin üzerinde kalması, eğitim sürecinin son aşamalarında doğrulama performansında dalgalanmalar meydana gelebildiğini göstermektedir.

Aşırı öğrenme (overfitting), eğitim verisindeki başarımın artmasına rağmen doğrulama veya test performansının bozulmasıyla ilişkilidir. Bu nedenle son doğrulama kaybındaki artış, aşırı öğrenme açısından bir uyarı göstergesi olarak değerlendirilmiş ancak tek başına kesin kanıt kabul edilmemiştir.

Yetersiz öğrenme (underfitting) ise modelin eğitim verisindeki ilişkileri yeterince temsil edememesiyle karakterize edilir. Çalışmada eğitim doğruluklarının genel olarak %92–94 aralığında bulunması, modellerin veri kümesindeki sınıflandırma ilişkilerini önemli ölçüde öğrendiğini göstermektedir. Bununla birlikte, yalnızca doğruluk düzeylerinden hareketle yetersiz öğrenmenin tamamen ortadan kalktığı sonucuna varılamaz.

Bu gözlemler, model karmaşıklığının artırılmasının tek başına genelleme başarımını garanti etmediğini ve eğitim sürecinin doğrulama metrikleriyle birlikte değerlendirilmesi gerektiğini göstermektedir.

5.5. Eğitim ekran görüntüleri ve özgün deney arşivi

Ana deneylerin her biri için eğitim doğruluğu, kayıp ve karışıklık matrisi çıktıları yerel deney arşivinde oluşturulmuştur (27 × 3 = 81 görsel).

5.6. L2 Düzenlileştirme Deneyi

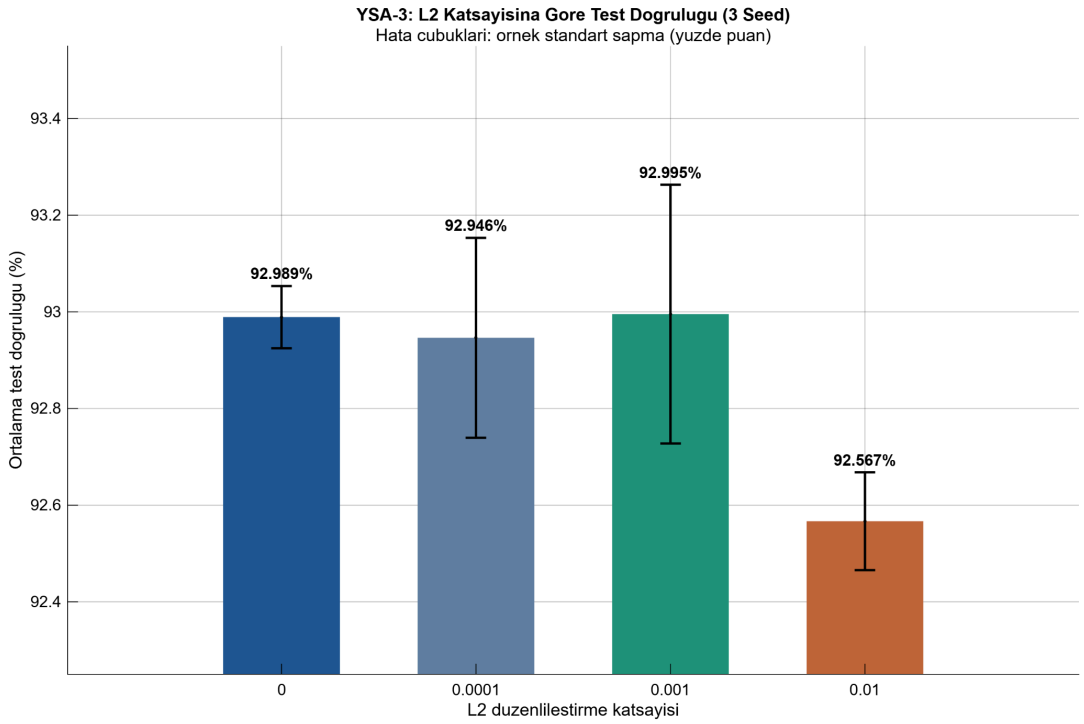
Ek deney, ana çalışmada en yüksek ortalama test doğruluğunu veren YSA-3 mimarisinin %60/%40 bölmesi üzerinde yürütülmüştür. Ağ mimarisi (16–32–16–8–7), veri bölmesi, ön işleme, Adam optimizasyonu, öğrenme oranı (0,001), mini-batch boyutu (128) ve eğitim süresi (50 epoch) sabit tutulmuştur. Başlangıç tohumları 101, 202 ve 303 olarak eşleştirilmiştir. Orijinal modellerin L2 katsayısının 0,0001 olduğu kayıtlı eğitim seçeneklerinden doğrulanmış; L2 = 0, 0,001 ve 0,01 koşulları için dokuz yeni model eğitilmiştir. Böylece üç mevcut kontrol ile toplam 12 karşılaştırma kaydı elde edilmiştir. Eğitim seçenekleri MATLAB `trainingOptions` arayüzü üzerinden yapılandırılmıştır [16].

Tablo 7. YSA-3 (%60/%40) için L2 katsayısına göre üç tohumlu deneylerin özeti (ortalama ± örnek standart sapma).

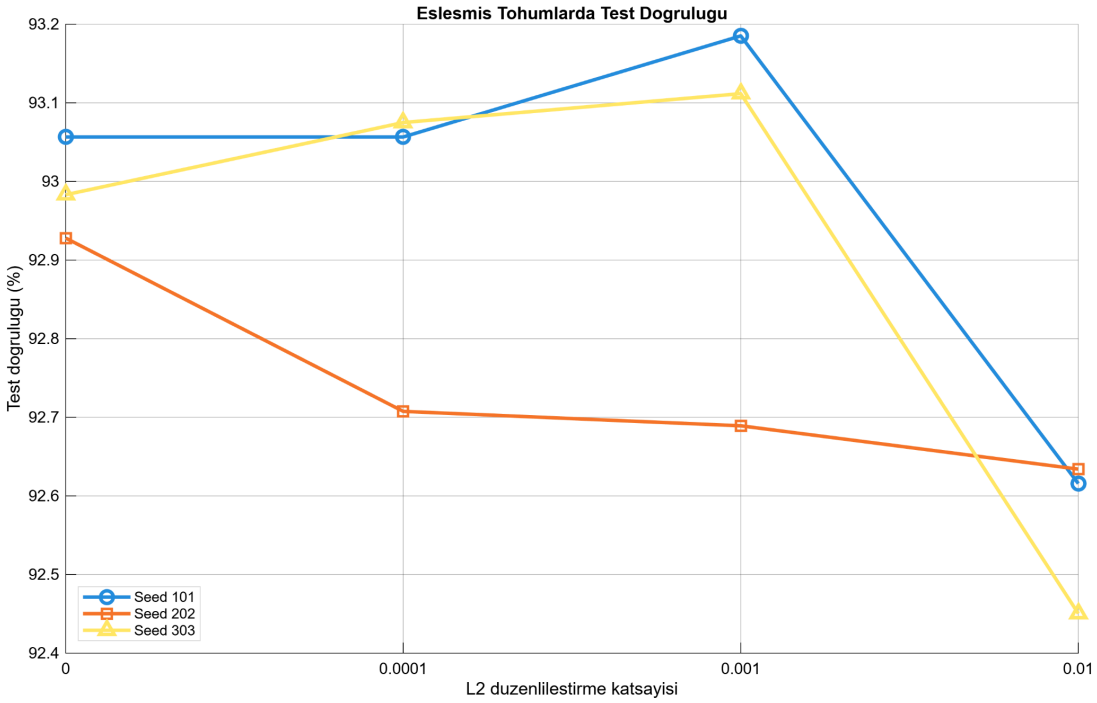
L2	Eğitim (%)	Doğrulama (%)	Test (%)	Macro-F1	Min. val. kaybı
0	93,225 ± 0,151	91,953 ± 0,187	92,989 ± 0,065	0,94106 ± 0,00050	0,23174 ± 0,00379
0,0001 (kontrol)	93,157 ± 0,130	92,034 ± 0,123	92,946 ± 0,207	0,94080 ± 0,00169	0,23222 ± 0,00245
0,001	93,071 ± 0,100	91,871 ± 0,255	92,995 ± 0,268	0,94113 ± 0,00212	0,23204 ± 0,00228
0,01	92,450 ± 0,122	91,544 ± 0,212	92,567 ± 0,101	0,93782 ± 0,00104	0,25103 ± 0,00327

Tablo 8. Orijinal L2 = 0,0001 koşuluna göre ortalama test doğruluğu farkları (yüzde puan).

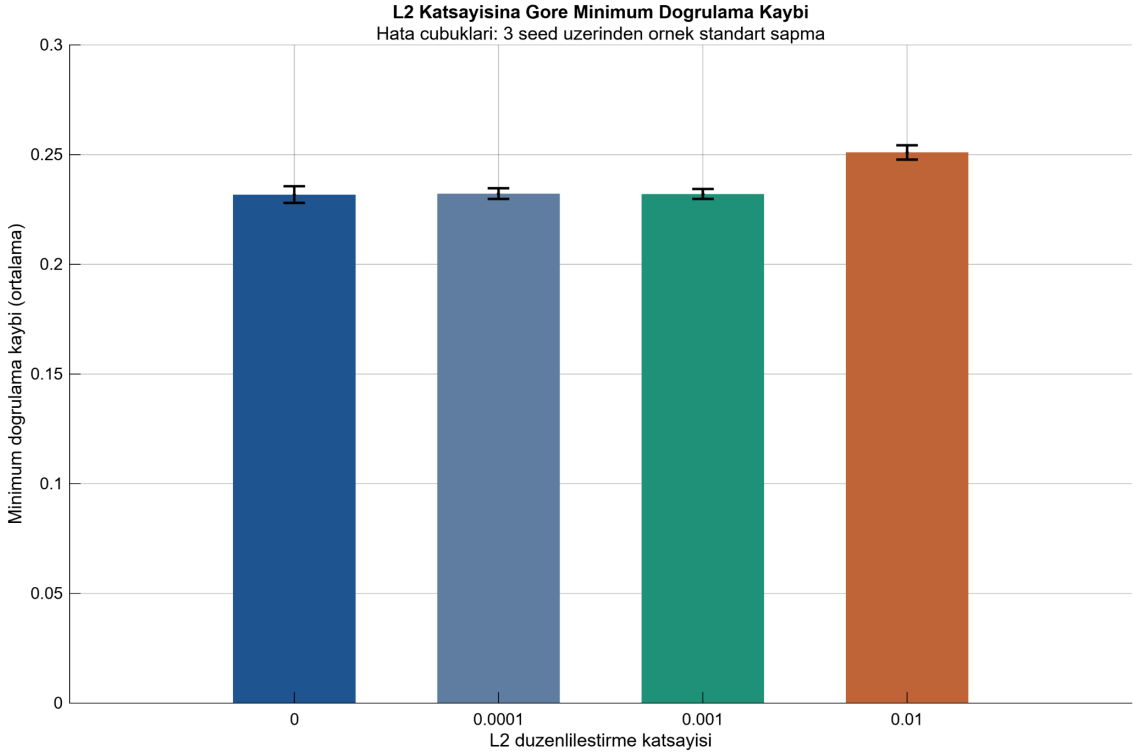
L2	Test ortalaması (%)	Kontrole göre fark (yp)
0	92,989	+0,043
0,0001	92,946	0,000
0,001	92,995	+0,049
0,01	92,567	−0,380



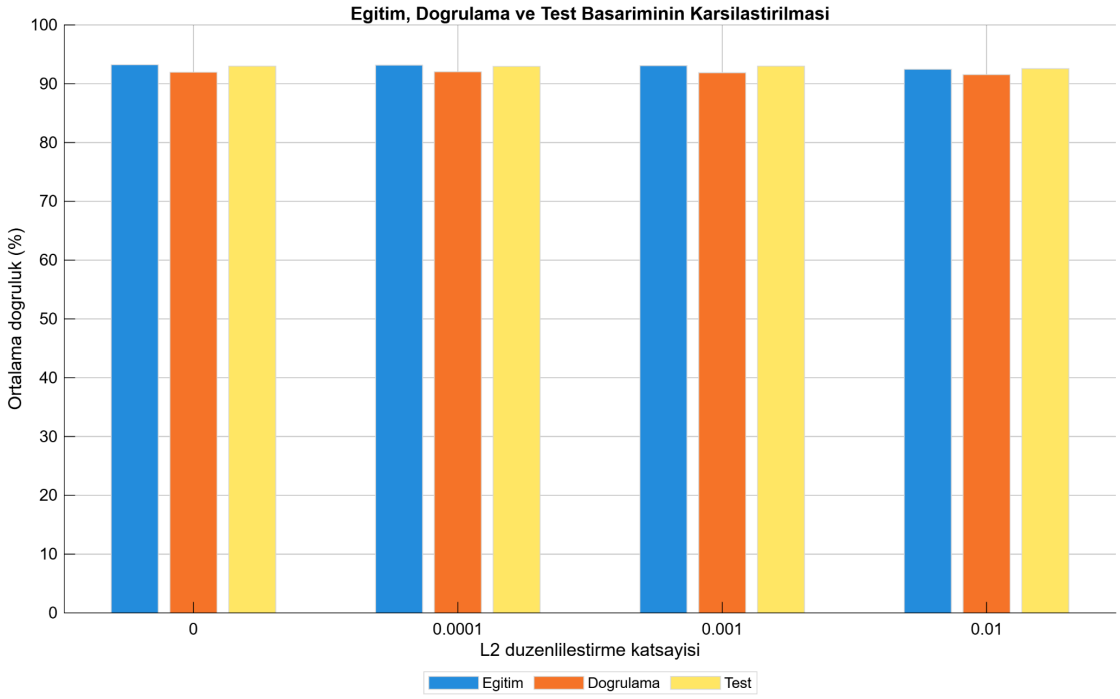
Şekil 4. L2 katsayısına göre ortalama test doğruluğu ve standart sapma.



Şekil 5. Eşleştirilmiş tohumlarda test doğruluğunun değişimi.



Şekil 6. L2 katsayısına göre minimum doğrulama kaybı.



Şekil 7. Eğitim, doğrulama ve test doğruluklarının karşılaştırılması.

Üç tohum ortalamasında en yüksek test doğruluğu L2 = 0,001 için %92,995; en düşük ortalama minimum doğrulama kaybı ise L2 = 0 için 0,23174 olarak hesaplanmıştır. Test başarımındaki 0,049 yüzde puanlık farkın küçük olduğu ve üç tekrarın istatistiksel üstünlük iddiası için yeterli olmadığı vurgulanmalıdır. Test kümesi, L2 seçimi için değil, sonuçların son değerlendirmesi için kullanılmalıdır. L2 ek deneyinin mimarisi ana deneylerin test sonuçlarına göre belirlendiğinden, bu karşılaştırma keşifsel nitelikte değerlendirilmiş ve bağımsız bir test kümesinde doğrulanmış hiperparametre optimizasyonu olarak yorumlanmamıştır. L2 katsayısının etkisi; eğitim, doğrulama ve test doğruluğu, Macro-F1 ve minimum doğrulama kaybı ölçütleri üzerinden değerlendirilmiştir.

6. TARTIŞMA

Üç mimarinin tamamı yüksek ve birbirine yakın doğruluklar üretmiştir. Daha derin YSA-3, üç oranın ikisinde en yüksek ortalama test doğruluğuna ulaşsa da %70/%30 koşulunda YSA-2 daha yüksek sonuç vermiştir. Dolayısıyla artan ağ derinliğinin her koşulda üstün olduğu söylenemez. Macro-F1 eğilimi genel olarak test doğruluğuyla uyumludur. Bununla birlikte, sınıf bazında hangi hataların yoğunlaştığını belirlemek için karışıklık matrislerinin ve sınıf düzeyindeki başarım ölçütlerinin ayrıntılı olarak incelenmesi gerekir.

Dikkat çekici biçimde %80/%20 oranı en yüksek test doğruluğunu vermemiştir. Bu, “daha fazla eğitim verisi daha kötü model üretir” anlamına gelmez, farklı oranlar farklı test örneklerini içerdiğinden gözlenen değişim test kümesinin güçlüğü ve rastgele bölme etkileriyle ilişkili olabilir. Ayrıca doğrulama kümesi

oranı eğitim havuzuna bağlı olarak değişmektedir. Bu nedenle oran etkisini izole etmek için ortak sabit test kümesi ve çoklu bölme tekrarlarıyla ek deney gerekir [13], [15].

6.1. Düzenlileştirmenin Genelleme Performansına Etkisi

L2 = 0, 0,0001 ve 0,001 koşullarında ortalama test doğrulukları birbirine yakındır (%92,946–%92,995). L2 = 0,01 için ortalama test doğruluğu %92,567'ye, eğitim doğruluğu %92,450'ye düşmüş; minimum doğrulama kaybı 0,25103'e yükselmiştir. Bu birlikte gözlenen değişimler, güçlü düzenlileştirmenin bu kurulumda modelin veri örüntülerine uyumunu kısıtlamış olabileceğiyle tutarlıdır; tek başına kesin bir underfitting tanısı değildir. Ayrıca üç eşleştirilmiş tohum ve tek veri bölmesiyle gözlenen küçük farklar genellenebilir ya da istatistiksel olarak anlamlı kazanımlar olarak yorumlanmamalıdır. Orijinal 27 deneyde 21 koşulda son doğrulama kaybının minimumdan yüksek olması, geç dönem genelleme davranışının izlenmesi gerektiğine işaret eder; bu gözlem tek başına overfitting kanıtı değildir.

7. SINIRLILIKLAR

Çalışma tek veri setiyle sınırlıdır. Sonuçlar başka tarımsal ürünlere veya farklı veri kaynaklarına doğrudan genellenemez. Her oran için tek bir veri bölmesi kullanılmıştır. Üç tekrar yalnızca farklı ağırlık başlangıcı ve eğitim rastgeleliğini örneklemektedir. Sabit hiperparametreler seçilmiş, sistematik arama yapılmamıştır. Üç tekrarın küçük örneklem büyüklüğü, istatistiksel anlamlılık iddialarını desteklemez. L2 karşılaştırması yalnızca YSA-3 mimarisi, %60/%40 veri bölmesi ve üç tohumla sınırlıdır. Farklı L2 katsayılarının diğer mimarilerde veya farklı bölmelerde aynı etkiyi göstereceği varsayılamaz. Test kümesine göre hiperparametre seçimi yapılmamalı; seçimin doğrulama ölçütleriyle önceden belirlenmesi gerekir.

8. SONUÇ

Bu çalışmada Dry Bean veri seti üzerinde üç ileri beslemeli YSA mimarisi, üç eğitim havuzu/test oranı ve üç tekrarla toplam 27 ana eğitim gerçekleştirilmiştir. En yüksek ana deney grup ortalaması, YSA-3 ve %60/%40 koşulunda %92,946 test doğruluğudur. Bu mimaride gerçekleştirilen dokuz ek L2 eğitimiyle, üç mevcut kontrol modeli dahil toplam 12 kayıt karşılaştırılmıştır. L2 = 0,001 ortalama %92,995 test doğruluğu sağlamış, ancak kontrol koşuluna göre fark yalnızca 0,049 yüzde puan olmuştur. L2 = 0,01 koşulunda test doğruluğu ve doğrulama kaybı birlikte kötüleşmiştir. Bulgular, mimari karmaşıklığı ve düzenlileştirme düzeyinin performans üzerindeki etkilerinin deneysel olarak izlenebileceğini göstermektedir. Tek veri kümesi ve sınırlı tekrar sayısı nedeniyle genelleme ve istatistiksel üstünlük iddialarından kaçınılmıştır. MATLAB kaynak kodları, sayısal sonuçlar ve görseller GitHub bağlantısıyla sunulmuştur.

KAYNAKLAR

[1] M. Koklu and I. A. Ozkan, “Multiclass classification of dry beans using computer vision and machine learning techniques,” Computers and Electronics in Agriculture, vol. 174, art. 105507, 2020. https://doi.org/10.1016/j.compag.2020.105507

[2] M. Koklu and I. A. Ozkan, “Dry Bean,” UCI Machine Learning Repository, 2020. https://doi.org/10.24432/C50S4B

[3] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” Nature, vol. 323, pp. 533–536, 1986. https://doi.org/10.1038/323533a0

[4] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” Nature, vol. 521, pp. 436–444, 2015. https://doi.org/10.1038/nature14539

[5] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. MIT Press, 2016. https://mitpress.mit.edu/9780262337373/deep-learning/

[6] C. M. Bishop, Pattern Recognition and Machine Learning. Springer, 2006. https://link.springer.com/book/9780387310732

[7] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning, 2nd ed. Springer, 2009. https://doi.org/10.1007/978-0-387-84858-7

[8] X. Glorot and Y. Bengio, “Understanding the difficulty of training deep feedforward neural networks,” AISTATS, PMLR 9, pp. 249–256, 2010. https://proceedings.mlr.press/v9/glorot10a.html

[9] K. He, X. Zhang, S. Ren, and J. Sun, “Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification,” ICCV, pp. 1026–1034, 2015. https://openaccess.thecvf.com/content_iccv_2015/html/He_Delving_Deep_into_ICCV_2015_paper.html

[10] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” ICLR, 2015. https://mlanthology.org/iclr/2015/kingma2015iclr-adam/

[11] N. Srivastava et al., “Dropout: A simple way to prevent neural networks from overfitting,” JMLR, vol. 15, pp. 1929–1958, 2014. https://jmlr.org/papers/v15/srivastava14a.html

[12] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” ICML, PMLR 37, pp. 448–456, 2015. https://proceedings.mlr.press/v37/ioffe15.html

[13] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” IJCAI, pp. 1137–1144, 1995. https://ijcai.org/proceedings/1995/147

[14] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” Information Processing & Management, vol. 45, no. 4, pp. 427–437, 2009. https://doi.org/10.1016/j.ipm.2009.03.002

[15] T. G. Dietterich, “Approximate statistical tests for comparing supervised classification learning algorithms,” Neural Computation, vol. 10, no. 7, pp. 1895–1923, 1998. https://doi.org/10.1162/089976698300017197

[16] MathWorks, “trainingOptions: Options for training deep learning neural network,” MATLAB Documentation. https://www.mathworks.com/help/deeplearning/ref/trainingoptions.html

EK A. Kod, Modeller ve Deneysel Sonuçların Erişilebilirliği

GitHub: https://github.com/aslisemsimoglu/DryBean-ANN-MATLAB-27Experiments